Descripción del origen de datos

El archivo **01- Informe_Ventas.xlsx** contiene información sobre la actividad comercial de una empresa dedicada a la venta de productos a través de Internet.

La base de datos recoge operaciones comerciales realizadas entre el **1 de diciembre de 2010 y el 9 de diciembre de 2011**, correspondientes a clientes de diferentes países.

El libro de Excel contiene dos hojas:

- **Online Retail:** contiene los registros de las operaciones comerciales.
- **Diccionario:** proporciona información sobre el significado de los principales campos de la base de datos.

1. Ventas (Online Retail)

Contiene **541.909 registros**, organizados en 10 campos.

Cada registro representa una línea de una factura, es decir, un producto incluido en una operación comercial. Por tanto, una misma factura puede aparecer en varios registros si contiene varios productos.

Los campos disponibles son:

- **InvoiceNo:** número que identifica la factura correspondiente a la operación.
- **StockCode:** código identificativo del producto.
- **Description:** descripción o nombre del producto.
- **Quantity:** número de unidades del producto incluidas en la operación.
- **InvoiceDate:** fecha y hora de la factura.
- **UnitPrice:** precio unitario del producto.
- **CustomerID:** identificador del cliente que realiza la compra.
- **Country:** país asociado al cliente.
- **Country2:** segunda columna con información sobre el país.

2. Diccionario de datos

Esta hoja contiene una descripción de los principales campos utilizados en la tabla de ventas.

Su finalidad es facilitar la interpretación de la información y ayudar a establecer los tipos de datos adecuados durante los procesos de importación y transformación.

Características de la información

La base de datos contiene información que permite estudiar distintos aspectos de la actividad comercial de la empresa:

- Las facturas registradas y los productos incluidos en cada una.
- Las cantidades de productos vendidos o devueltos.
- Los precios unitarios de los productos.
- Los clientes asociados a las operaciones.
- La distribución geográfica de las ventas.
- Las fechas en las que se realizaron las operaciones.

Los datos presentan algunas particularidades que deberán tenerse en cuenta durante su preparación:

- Existen campos con valores nulos o sin información.
- Algunas cantidades son negativas, lo que puede estar relacionado con devoluciones o ajustes.
- Algunos productos presentan precios unitarios iguales a cero.
- Determinados campos contienen identificadores numéricos que no deben utilizarse como cantidades.
- Existen columnas cuya utilidad y posible redundancia deben comprobarse.
- Es necesario revisar los tipos de datos asignados a cada campo.

Objetivo del ejercicio

El archivo se utilizará como origen de datos para trabajar con **Power BI Desktop y Power Query**.

Se pretende que el alumnado aprenda a importar información desde Excel, identificar y comprender los campos disponibles, revisar la calidad de los datos y aplicar las transformaciones necesarias para preparar la información.

El volumen de registros permitirá, además, familiarizarse con el tratamiento de conjuntos de datos grandes y comprender la importancia de realizar correctamente los procesos de limpieza y transformación.

Una vez preparados los datos, podrán utilizarse para analizar la actividad comercial mediante tablas, gráficos e informes interactivos.

Estructura de los datos

El archivo contiene una única hoja principal de operaciones, en la que se repiten determinados datos.

Por ejemplo, una misma factura puede incluir varios productos:

InvoiceNo	StockCode	Description	Quantity
536365	85123A	WHITE HANGING HEART T-LIGHT HOLDER	6
536365	71053	WHITE METAL LANTERN	6
536365	84406B	CREAM CUPID HEARTS COAT HANGER	8
536365	84029G	KNITTED UNION FLAG HOT WATER BOTTLE	6

En los cuatro registros aparece el mismo número de factura, pero cada uno corresponde a un producto distinto.

Esto permite explicar por qué el número de registros no coincide con el número de facturas.

Características del archivo comprobadas

Característica	Resultado
Registros de operaciones	541.909
Columnas	10
Facturas diferentes	25.900
Códigos de productos diferentes	4.070
Clientes identificados diferentes	4.372
Países diferentes	38
Registros sin CustomerID	135.080
Registros sin Description	1.454
Registros con Quantity negativa	10.624
Registros con UnitPrice igual a cero	2.515

Registros con UnitPrice negativo	2

Los recuentos corresponden al archivo original, antes de aplicar transformaciones o filtros.

Observaciones para preparar los ejercicios

El archivo es especialmente adecuado para practicar los siguientes contenidos de la Unidad 1:

1. Importación de una hoja de Excel con más de 500.000 registros.
2. Comprobación de los tipos de datos.
3. Identificación y tratamiento de valores nulos.
4. Filtrado de operaciones con cantidades negativas.
5. Filtrado de productos sin descripción.
6. Identificación de precios iguales a cero.
7. Eliminación de columnas innecesarias.
8. Cambio de nombre de columnas.
9. Creación de una columna calculada de importe mediante Quantity × UnitPrice.
10. Carga y actualización de los datos transformados.

Conviene advertir de que las cantidades negativas y los precios cero no deben eliminarse automáticamente: primero hay que determinar qué representan y qué operaciones deben incluirse en el análisis.

Utilizaría este archivo completo para mostrar por qué Power Query es especialmente útil cuando trabajamos con grandes volúmenes de información.